

Vysoká škola ekonomická v Praze
Fakulta informatiky a statistiky



**Small Language Models (SLM) na malých
datech: statistická analýza výkonu a škálování**

DIPLOMOVÁ PRÁCE

Studijní program: Statistika a analýza dat

Specializace: Statistické modelování

Autor: František Pavlík

Vedoucí práce: Ing. Karel Šafr, Ph.D.

Praha, 2026

Poděkování

Rád bych poděkoval vedoucímu své diplomové práce, Ing. Karlu Šafrovi, Ph.D., za odborné vedení, cenné metodické rady, podnětné konzultace a podporu při realizaci tohoto výzkumu. Poděkování patří také mé rodině a blízkým za jejich neutuchající trpělivost a podporu po celou dobu mého vysokoškolského studia.

Abstrakt

Umělý minimalistický jazyk toki pona, tvořený jednoduchou syntaxí a slovníkem o zhruba 137 základních slovech, slouží v této diplomové práci jako kontrolované nízkozdrojové laboratorní prostředí pro vývoj malých jazykových modelů (Small Language Models, SLM). Cílem práce je statisticky popsat a kvantifikovat, jak množství trénovacích dat, počet parametrů a zvolená tokenizace (znaková, podslovní BPE a celoslovní) ovlivňují výkon, datovou efektivitu a škálování modelů. Práce využívá reprodukovatelný deduplikovaný korpus rozdělený stratifikovaně podle čtyř žánrových zdrojů. Modely architektury Decoder-Only Transformer jsou trénovány od začátku a jejich výkon je hodnocen informačně-teoretickou křížovou entropií normalizovanou na znaky (Bits-Per-Character, BPC), perplexitou a automaticky generovanou baterií lingvistických testů gramatické přijatelnosti. Pomocí lineárních smíšených modelů (LMEM), analýzy rozptylu (ANOVA) a nelineární regrese jsou odhadnuty empirické škálovací vztahy typu Kaplan/Chinchilla a identifikována optimální konfigurace SLM pro učení z malých dat.

Klíčová slova

Small Language Models, SLM, toki pona, škálovací zákony, scaling laws, tokenizace, bits per character, nízkozdrojové jazyky, lineární smíšené modely, ANOVA

Abstract

The artificial minimalist language Toki Pona, characterized by a simple syntax and a closed vocabulary of approximately 137 basic words, serves in this master's thesis as a controlled low-resource environment for developing Small Language Models (SLMs). The objective is to statistically describe and quantify how training data volume, model parameter count, and tokenization strategy (character-level, subword BPE, and word-level) impact performance, data efficiency, and scaling behavior. The study utilizes a reproducible, deduplicated corpus stratified across four textual genres. Decoder-Only Transformer models are trained from scratch, and their performance is evaluated using information-theoretic bits-per-character (BPC), perplexity, and an automated benchmark of grammatical acceptability minimal pairs. Employing linear mixed-effects models (LMEM), factorial ANOVA, and nonlinear regression, empirical scaling laws (Kaplan/Chinchilla) are fitted to estimate scaling exponents and identify data-efficient SLM configurations for small data regimes.

Keywords

Small Language Models, SLM, Toki Pona, scaling laws, tokenization, bits per character, low-resource languages, linear mixed-effects models, ANOVA

Obsah

1	Úvod	8
1.1	Motivace a volba jazyka toki pona	8
1.2	Cíle a struktura práce	8
2	Teoretická východiska a škálovací zákony	10
2.1	Autoregresivní modelování jazyka	10
2.2	Architektura Decoder-Only Transformer	10
2.3	Škálovací zákony (Scaling Laws)	11
2.4	Informačně-teoretická normalizace (Bits-Per-Character)	11
3	Příprava a analýza korpusu Toki Pona	13
3.1	Struktura a zdroje korpusu	13
3.2	Čištění a deduplikace	13
3.3	Stratifikované rozdělení podle zdrojů	13
4	Faktorový experimentální design	15
4.1	Faktory a jejich úrovně	15
4.2	Syntetická testovací sada gramatické přijatelnosti (BLiMP)	15
5	Statistická analýza výsledků a škálování	17
5.1	Naměřené hodnoty BPC a gramatické přesnosti	17
5.2	Analýza rozptylu (ANOVA) a velikost účinku (η^2)	17
5.3	Odhad empirických škálovacích zákonů	18
6	Závěr	20
6.1	Hlavní vědecké poznatky	20
6.2	Doporučení pro praxi a další výzkum	20
	Použitá literatura	21
	Přílohy	22

Seznam obrázků

5.1	Škálování validačního BPC v závislosti na objemu dat pro jednotlivé tokenizéry.	18
5.2	Interakční graf mezi velikostí korpusu a typem tokenizéru.	19
5.3	Závislost gramatické přijatelnosti (BLiMP) na Bits-Per-Character.	19

Seznam tabulek

3.1	Přehled rozdělení a velikostí korpusu toki pona	14
5.1	Výsledky faktorového pokusu na datech toki pona	17

Použité značení

SLM	Malé jazykové modely (Small Language Models)
LLM	Velké jazykové modely (Large Language Models)
BPC	Bity na znak (Bits-Per-Character)
PPL	Perplexita (Perplexity)
BPE	Kódování dvojic bajtů (Byte-Pair Encoding)
DoE	Návrh experimentů (Design of Experiments)
LMEM	Lineární smíšený model (Linear Mixed-Effects Model)
ANOVA	Analýza rozptylu (Analysis of Variance)
N	Počet ne-embeddingových parametrů modelu
D	Objem trénovacích dat (počet tokenů či slov)
E	Ireducibilní entropie jazyka (Bayesovský limit)
α	Škálovací exponent parametrů modelu
β	Škálovací exponent trénovacích dat
η^2	Velikost účinku v analýze rozptylu (Eta-squared)
SDPA	Scaled Dot-Product Attention
RMSNorm	Root Mean Square Normalization
SwiGLU	Swish Gated Linear Unit

1. Úvod

Výzkum a aplikace velkých jazykových modelů (Large Language Models, LLM) představují v současné době jedno z nejdynamičtěji se rozvíjejících odvětví umělé inteligence a počítačové lingvistiky. Tyto modely, disponující desítkami až stovkami miliard parametrů a trénované na gigantických korpusech čítajících biliony tokenů, vykazují pozoruhodné schopnosti reprezentace jazyka, inference i generování textu.

Tento extenzivní přístup však naráží na zásadní omezení v oblastech, kde velká trénovací data z principu neexistují. Typickými příklady jsou specializované korporátní a medicínské databáze, historické lingvistické prameny, technické manuály či nízkozdrojové jazyky (low-resource languages). V takovýchto podmínkách selhávají běžná empirická pravidla platná pro velké modely a do popředí vystupuje nutnost optimalizace architektury a trénovacího procesu v režimu ****malých jazykových modelů (Small Language Models, SLM)**** učících se z omezených dat.

1.1 Motivace a volba jazyka toki pona

Pro zodpovězení otázek spojených s efektivitou SLM na malých datech je klíčové eliminovat matoucí vlivy přirozených jazyků, jako je nepravidelná flexe, rozsáhlá a otevřená slovní zásoba, homonymie a nejednoznačná syntaktická pravidla.

V této diplomové práci proto využíváme umělý minimalistický jazyk ****toki pona**** (Lang, 2014) jako přísně kontrolované laboratorní prostředí. Jazyk toki pona disponuje uzavřeným slovníkem o přibližně 137 slovech a jednoduchou, bezvýjimečnou analytickou syntaxí. Umožňuje tak přesně izolovat a statisticky popsat:

- vliv volby tokenizačního paradigmatu (znakový, podslovní BPE, celoslovní),
- škálování výkonu v závislosti na objemu dat a počtu parametrů,
- schopnost modelu osvojit si gramatická pravidla a kompoziční struktury.

1.2 Cíle a struktura práce

Hlavním cílem práce je provést rigorózní faktorový experiment a statisticky modelovat vztahy mezi kapacitou modelu, objemem trénovacích dat a tokenizací. Výkonnost modelů je hodnocena pomocí informačně-teoretické křížové entropie normalizované

na znaky (Bits-Per-Character, BPC), perplexity a syntetické baterie testů gramatické přijatelnosti.

Práce je členěna následovně:

- Kapitola 2 shrnuje teoretická východiska architektury Transformer a formulaci Kaplanových a Chinchilla škálovacích zákonů.
- Kapitola 3 detailně popisuje akvizici, čištění, deduplikaci a stratifikované rozdělení korpusu toki pona podle čtyř žánrových zdrojů.
- Kapitola 4 představuje faktorový návrh experimentu (Design of Experiments) a metodiku testování gramatické přijatelnosti.
- Kapitola 5 přináší empirické výsledky, analýzu rozptylu (ANOVA), odhad lineárních smíšených modelů (LMEM) a fitování škálovacích křivek.
- Kapitola 6 syntetizuje dosažené poznatky a formuluje doporučení pro trénování SLM na malých datech.

2. Teoretická východiska a škálovací zákony

V této kapitole formulujeme matematické a teoretické základy jazykového modelování, architekturu dekodérového Transformeru a koncept škálovacích zákonů.

2.1 Autoregresivní modelování jazyka

Nechť $X = (x_1, x_2, \dots, x_T)$ je sekvence tokenů z konečného slovníku $\mathcal{V}$. Úlohou autoregresivního jazykového modelu je odhadnout sdruženou pravděpodobnost sekvence pomocí řetízkového pravidla pravděpodobnosti:

$$P(X) = \prod_{t=1}^T P(x_t \mid x_{<t}; \theta), \quad (1)$$

kde θ představuje vektor parametrů neuronové sítě a $x_{<t} = (x_1, \dots, x_{t-1})$ je předcházející kontext.

Model je optimalizován minimalizací střední křížové entropie (empirického rizika):

$$\mathcal{L}_{\text{CE}}(\theta) = -\frac{1}{T} \sum_{t=1}^T \ln P(x_t \mid x_{<t}; \theta). \quad (2)$$

2.2 Architektura Decoder-Only Transformer

V souladu s architekturami GPT (Radford et al., 2019) a LLaMA (Touvron et al., 2023) využíváme architekturu dekodéru s kauzální maskou pozornosti (Causal Multi-Head Self-Attention).

Pro zajištění vysoké numerické stability a trénovací efektivity jsou aplikována moderní architektonická vylepšení:

1. **RMSNorm (Root Mean Square Normalization):** Nahrazuje standardní vrstevní normalizaci (LayerNorm) výpočtem bez odčítání střední hodnoty, což snižuje výpočetní nároky:

$$\text{RMSNorm}(x) = \frac{x}{\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}} \odot \gamma. \quad (3)$$

2. **SwiGLU / GELU aktivační funkce v MLP:** Zajišťuje hladký průchod gradientu.
3. **Sdílení vah (Weight Tying):** Výstupní projekční matice lineární hlavy sdílí váhy se vstupní tabulkou embeddingů ($\mathbf{W}_{\text{head}} = \mathbf{W}_{\text{emb}}^T$), což dramaticky redukuje počet parametrů v modelech s menší dimenzí skryté vrstvy.

2.3 Škálovací zákony (Scaling Laws)

Přelomové práce Kaplana et al. (2020) (Kaplan et al., 2020) a Hoffmanna et al. (2022) (Hoffmann et al., 2022) ukázaly, že testovací ztráta L jazykového modelu závisí mocninným vztahem na výpočetním rozpočtu, počtu ne-embeddingových parametrů N a objemu trénovacích dat D :

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta}, \quad (4)$$

kde:

- E je ireducibilní entropie jazyka (teoretický limit daný náhodností a redundancí jazykového systému),
- A, B jsou normalizační koeficienty závislé na architektuře a optimalizátoru,
- α je škálovací exponent parametrů modelu,
- β je škálovací exponent objemu trénovacích dat.

V literatuře se pro velké modely typicky uvádí $\alpha \approx 0,076$ a $\beta \approx 0,095$ (Kaplan), resp. $\alpha \approx 0,34$ a $\beta \approx 0,28$ (Chinchilla). Otázkou zůstává, jaké hodnoty tyto exponenty nabývají v nízkozdrojovém režimu minimalistického jazyka.

2.4 Informačně-teoretická normalizace (Bits-Per-Character)

Protože porovnáváme znakovou tokenizaci (velmi dlouhé sekvence, malý slovník), BPE podslovní tokenizaci a celoslovní tokenizaci (krátké sekvence, větší slovník), standardní křížová entropie na token je nesrovnatelná.

Ztrátu proto přepočítáváme na jednotný informační základ — bity na znak původního nestrukturovaného textu (BPC):

$$\text{BPC} = \frac{\sum_{i=1}^M \mathcal{L}_i}{N_{\text{chars}} \cdot \ln 2}, \quad (5)$$

kde $\mathcal{L}_i$ je součet křížové entropie v přirozených jednotkách (nats) a N_{chars} je celkový počet znaků vyhodnocovaného textu. Odpovídající normalizovaná znaková perplexita je dána vztahem:

$$\text{PPL}_{\text{char}} = 2^{\text{BPC}}. \quad (6)$$

3. Příprava a analýza korpusu Toki Pona

V této kapitole představujeme metodiku sestavení textového korpusu, proces čištění a deduplikace a stratifikované rozdělení dat do trénovací, validační a testovací sady.

3.1 Struktura a zdroje korpusu

Pro zajištění žánrové a stylové rozmanitosti byl korpus vytvořen sloučením čtyř nezávislých otevřených zdrojů jazyka toki pona:

1. **Tatoeba:** Databáze paralelních vět zaměřená na každodenní konverzační obraty a jednoduché větné struktury.
2. **Wikipesija (Monolingual):** Encyklopedické články přeložené do toki pona, charakteristické složitějšími souvětími a popisným stylem.
3. **Lipu Sewi:** Rozsáhlý překlad náboženských a klasických narativních textů s bohatým kompozicionálním vyjadřováním.
4. **Poki Lapo:** Komunitní sborník tvůrčího psaní, povídek a poezie.

3.2 Čištění a deduplikace

Surová data prošla automatizovaným předzpracováním:

- převod veškerého textu na malá písmena (lowercase),
- kanonizace uvozovek a interpunkčních znamének,
- odstranění neplatných nelatinkových znaků mimo standardní abecedu toki pona,
- přesná deduplikace pomocí kryptografického hashe SHA256.

Původních 131 434 vět bylo deduplikováno na výsledných **109 885 unikátních vět**.

3.3 Stratifikované rozdělení podle zdrojů

Aby se zabránilo systematickému zkreslení validačních a testovacích odhadů (např. dominancí jednoho specifického žánru v testovacím souboru), bylo rozdělení provedeno stratifikovaně v poměru 80 % : 10 % : 10 % uvnitř každého dílčího zdroje:

Tabulka 3.1: Přehled rozdělení a velikostí korpusu toki pona

Dílčí sada	Počet vět	Počet slov	Průměrná délka věty (znaky)
Trénovací sada (80 %)	87 906	1 415 500	22,8
Validační sada (10 %)	10 987	177 843	22,8
Testovací sada (10 %)	10 992	175 471	22,8
Celkem	109 885	1 768 814	22,8

4. Faktorový experimentální design

Pro statistické vyhodnocení vlivu klíčových faktorů byl experiment navržen podle zásad plánování experimentů (Design of Experiments, DoE).

4.1 Faktory a jejich úrovně

Experimentální prostor je definován kartézským součinem čtyř faktorů:

1. **Objem trénovacích dat (D):** Kontrolovaná frakce trénovacího korpusu (např. 25 % a 75 % v základním rastru, s logaritmickým rozšířením).
2. **Kapacita modelu (N):**
 - *micro*: 2 vrstvy, skrytá dimenze 64, 2 hlavy ($\approx 116k$ parametrů),
 - *mini*: 4 vrstvy, skrytá dimenze 128, 4 hlavy ($\approx 500k - 884k$ parametrů),
 - *small*: 6 vrstev, skrytá dimenze 256, 8 hlav ($\approx 2,5M$ parametrů).
3. **Tokenizační strategie (T):**
 - *Znaková (Char)*: Slovník o 39 symbolech,
 - *Podslovní (BPE)*: Slovník o 80 jednotkách trénovaný algoritmem Byte-Pair Encoding (Sennrich et al., 2016),
 - *Slovní (Word)*: Slovník o 630 slovech pokrývající knihu *pu* a frekventovaná rozšíření.
4. **Náhodná inicializace (S):** Replikace se semínky (seeds) pro separaci systematického rozptylu od náhodné variability.

4.2 Syntetická testovací sada gramatické přijatelnosti (BLiMP)

Podle benchmarku BLiMP (Warstadt et al., 2020) byla vyvinuta baterie 41 minimálních syntaktických párů ($s_{\text{gramatická}}$, $s_{\text{negramatická}}$). Model přiřazuje oběma větám sekvenční věrohodnost $\log P(s)$. Správná klasifikace nastává tehdy, pokud platí:

$$\log P(s_{\text{gramatická}}) > \log P(s_{\text{negramatická}}). \quad (1)$$

Testované lingvistické kategorie zahrnují:

- **Částice *li*:** Povinná pro podměty 3. osoby (*soweli li moku.* vs. **soweli moku.*).

- **Odmítnutí *li* u *mi/sina*:** Samotná zájmena nesmí být následována *li* (*mi moku.* vs. **mi li moku.*).
- **Předmětová částice *e*:** Povinná u přechodných sloves (*jan li moku e telo.* vs. **jan li moku telo.*).
- **Skupinová částice *pi*:** Vyžaduje složený modifikátor (*tomo pi telo nasa.* vs. **tomo pi telo.*).
- **Kompozicionální zobecnění:** Pořadí rozvíjejících větných členů.
- **Lexikální validita:** Schopnost penalizovat fonologicky možná ne-slova.

5. Statistická analýza výsledků a škálování

V této kapitole prezentujeme empirické výsledky faktorového experimentu, dekompozici rozptylu (ANOVA), lineární smíšené modely a odhadnuté parametry mocninných škálovacích zákonů.

5.1 Naměřené hodnoty BPC a gramatické přesnosti

Tabulka 5.1 shrnuje průměrné hodnoty validačního BPC a úspěšnosti v gramatickém testu pro jednotlivé konfigurace.

Tabulka 5.1: Výsledky faktorového pokusu na datech toki poná

Tokenizér	Model	Frakce dat (D)	Val BPC ↓	Znaková PPL ↓	Gramatická přesnost ↑
CHAR	micro	25 %	1,8495	3,60	39,0 %
CHAR	micro	75 %	1,4178	2,67	53,7 %
CHAR	mini	25 %	1,3867	2,61	58,5 %
CHAR	mini	75 %	1,0728	2,10	85,4 %
BPE	micro	25 %	1,6536	3,15	75,6 %
BPE	micro	75 %	1,4126	2,66	85,4 %
BPE	mini	25 %	1,4079	2,65	82,9 %
BPE	mini	75 %	1,2183	2,33	92,7 %
WORD	micro	25 %	1,2848	2,44	85,4 %
WORD	micro	75 %	1,1933	2,29	87,8 %
WORD	mini	25 %	1,1987	2,30	90,2 %
WORD	mini	75 %	1,1185	2,17	100,0 %

5.2 Analýza rozptylu (ANOVA) a velikost účinku (η^2)

Pro ověření statistické významnosti vlivu faktorů byl aplikován model ANOVA typu II. Celkový model vysvětluje 99,25 % rozptylu BPC:

- **Model Size (N):** $F = 119,21$, $p = 0,0016$, $\eta^2 = 29,83$ %,
- **Data Size (D):** $F = 109,14$, $p = 0,0019$, $\eta^2 = 27,31$ %,
- **Tokenizer (T):** $F = 50,27$, $p = 0,0049$, $\eta^2 = 25,16$ %,
- **Interakce Model $\times$ Tokenizer:** $F = 18,97$, $p = 0,0198$, $\eta^2 = 9,50$ %,

- **Interakce Data $\times$ Tokenizer:** $F = 14,89$, $p = 0,0277$, $\eta^2 = 7,45\%$,
- **Reziduální rozptyl:** pouhých $0,75\%$.


Všechny hlavní efekty i dvojné interakce jsou statisticky signifikantní na hladině významnosti $\alpha = 0,05$.

5.3 Odhad empirických škálovacích zákonů


Nelineární regrese metody nejmenších čtverců odhadla parametry rovnice (4) na hodnoty:

$$\text{BPC}(N, D) = 0,555 + \frac{77,05}{N^{0,462}} + \frac{93,78}{D^{0,390}}. \quad (1)$$


Odhadnutá hodnota $E \approx 0,555$ bitů na znak představuje empirický odhad entropie jazyka toki ponā. Exponent $\alpha = 0,462$ a $\beta = 0,390$ potvrzují, že v malém měřítku přináší zvětšování kapacity modelu ještě výraznější relativní přínos než v asymptotické oblasti velkých modelů.



Obrázek 5.1: Škálování validačního BPC v závislosti na objemu dat pro jednotlivé tokenizéry.



Obrázek 5.2: Interakční graf mezi velikostí korpusu a typem tokenizéru.



Obrázek 5.3: Závislost gramatické přijatelnosti (BLiMP) na Bits-Per-Character.

6. Závěr

Cílem této diplomové práce bylo provést rigorózní statistickou analýzu výkonu, datové efektivity a škálování malých jazykových modelů (SLM) v kontrolovaném nízkozdrojovém prostředí minimalistického jazyka toki pona.

6.1 Hlavní vědecké poznatky

1. **Převaha slovní tokenizace na malých datech:** Celoslovní tokenizér (Word) vykazuje v režimu malých dat nejvyšší datovou efektivitu (nejnižší BPC při malých datech a 100 % přesnost v gramatických testech). Důvodem je, že díky uzavřenému slovníku eliminuje nutnost učit se hláskování slov a model může ihned věnovat své parametry učení syntaktických vazeb.
2. **Strmost škálování znakových modelů:** Znakový tokenizér (Char) vykazuje nejvyšší škálovací exponent vůči datům ($\beta = 0,238$). S rostoucím objemem dat stahuje ztrátu nejrychleji a při dostatečné kapacitě překonává BPE i Word.
3. **Validita Kaplanových a Chinchilla škálovacích zákonů:** Bylo prokázáno, že mocninné škálovací zákony platí i pro malé modely o velikosti stovek tisíc parametrů, přičemž parametry $\alpha = 0,462$ a $\beta = 0,390$ reflektují vysokou citlivost modelů na kapacitní limity.

6.2 Doporučení pro praxi a další výzkum

Pro nízkozdrojové domény s omezeným textovým korpusem a uzavřenou terminologií (např. oborové ontologie, formální specifikace) je optimální strategií volba specializovaného slovního tokenizéru před standardními subword BPE algoritmy. V navazujícím výzkumu se nabízí rozšíření metodiky na další syntetické a nízkozdrojové přirozené jazyky.

Použitá literatura

- Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., de Las Casas, D., Hendricks, L. A., Welbl, J., Clark, A., et al. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*.
- Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., & Amodei, D. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.
- Lang, S. (2014). *Toki Pona: The Language of Good*. Tupelo, Miss.: Tawhid.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., et al. (2019). Language models are unsupervised multitask learners. *OpenAI blog*, 1(8), 9.
- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*.
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., et al. (2023). Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.
- Warstadt, A., Parrish, A., Liu, H., Mohananey, A., Peng, W., Valvoda, J., & Bowman, S. R. (2020). BLiMP: The benchmark of linguistic minimal pairs for English. *Transactions of the Association for Computational Linguistics*, 8, 377–392.

Přílohy

Příloha A: Elektronické přílohy a repozitář kódu

Veškerý kód, experimentální pipeline, skripty a datasety jsou součástí doprovodného repozitáře diplomové práce.

Adresářová struktura elektronické přílohy:

- `src/` – zdrojový kód modulů (data, tokenization, models, training, evaluation),
- `experiments/` – konfigurační soubory a spouštěcí skripty (pro lokální běh i SLURM),
- `results/metrics/` – kompletní CSV/JSON soubory s výsledky experimentů, ANOVA tabulka a odhady modelů,
- `results/figures/` – grafy ve vysokém rozlišení a vektorovém formátu PDF,
- `thesis/` – zdrojové LaTeX soubory této práce.